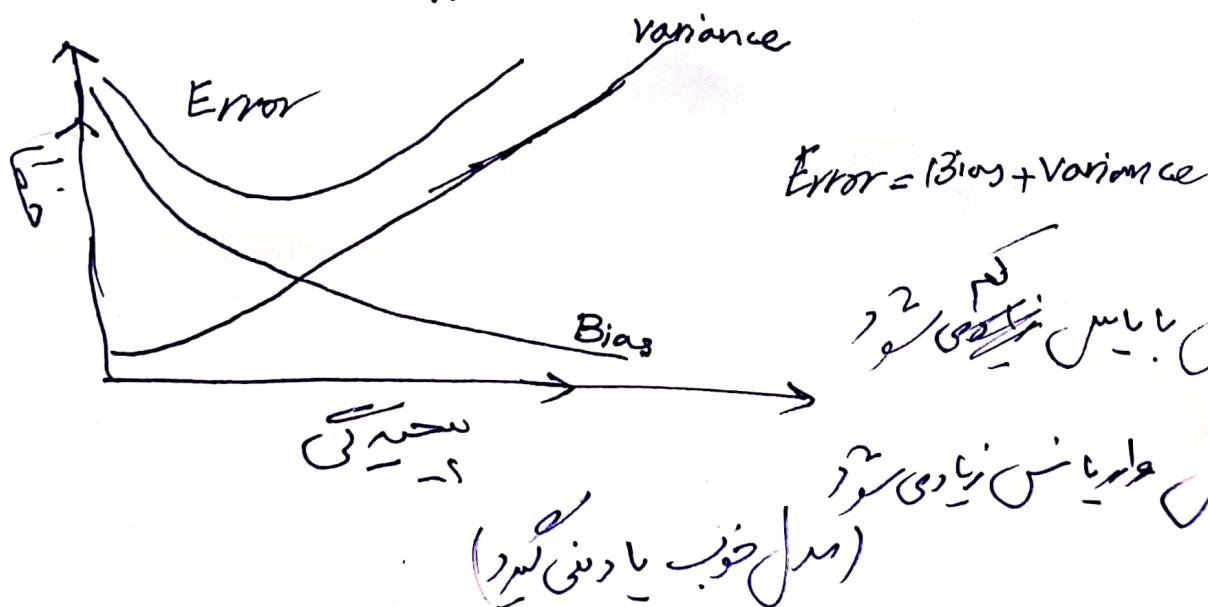


$$\begin{aligned}
 \text{MSE} &= E_D[(g^{(D)}(x) - f(x))^2] = E_D[(g^{(D)} - \bar{g}) + (\bar{g} - f(x))]^2 = * \\
 \bar{g} &= E_D[g^{(D)}(x)] \quad * = E_D[(g^{(D)} - \bar{g})^2 + (\bar{g} - f(x))^2 + 2(g^{(D)} - \bar{g})(\bar{g} - f(x))] \\
 &= E_D[(g^{(D)} - \bar{g})^2] + \underbrace{E[(\bar{g} - f(x))^2]}_{\text{bias}} + \underbrace{\text{variance}}
 \end{aligned}$$

(1)(1)



باقی از بحثی که باید می‌شود  
با اینکه این مجموعه از داده‌ها را  
نمی‌توان خوب نامناسب نامید

- ۱ استفاده از ~~features~~ ویژگی های ~~feature~~: ممکن است ویژگی های مهم در دست اخراج شوند
- ۲ استفاده از نسل پیچیده تر: ممکن است نسل توانایی ~~capture~~ صحیح را بدهیں خوبی در وسیع نداشته باشد
- ۳ کم کردن ~~penalty~~: Regularization: هایپر پارامترها نسبت مابین مجموع مدل و داده ها کم کردن است با تغییر آن بتوان سنتز بالا را حاصل کرد.
- ۴ ترین کردن پیش باده های مورد نظر

۱) با حذف عویضی هایی تغییر دارد generalization ماتعینم بینی مدل زیاد  $\hat{h}(x)$  می شود اما ممکن است دقت مدل روی داده های Train کم شود این دو نتیجه به عنوان صفاتی داریانش نم و بلیس زیادی شود.

البته این کار تا جایی آغاز می شود که عویضی هایی که حذف کرده ایم تغییر باشند از پیش جای خواهد بود که دیگری های غنیمت حذف می شوند، مدل بهترین فن شود و حتماً بلیس و حتماً داریانش بالای رود.

۱) ت اسْعَاده از ویدئو طای دسته: ممکن است مدل دیرگی های اصنافی را باید در قیمة باش  
که تأثیری نداشت نداشته

۲) اسْعَاده از مدل تدریجی ساده تر: ممکن است مدل سطوح زن بین ارزشی های پیشنهادی باش

۳) افتراض شرط داده شا: می تواند محدود باشد

۴) افتراض bias، بیوس Regularization

پیشگاهای داده هسته برای حل مسئله bias اکثر باهم مقادیر هسته برای معنی  
لارم است که عکال بیوس احتمال

۱) اگر جنده و پیری در مدل با هم هم بستگی بالای داشته باشند (highly correlated) خطف کسی در این مدل تأثیر ندارد یعنی این مدل ثابت است و تقریباً هست مدلی که داده های تازین ثابت می شوند اما واریانس مدل کم خواهد شد و مدل generalization بسیار خواهد داشت زیرا کسر نویز میان روابط متغیرهای را باید کم کرد.

99 210259

٣) خوب است باستimation با روش MLE (استنادی) یک point estimate (تحمیل تقدیری)

برای مدل پیدا کنیم و میان میان را حساب کنیم.

$$y = \bar{x}^T \theta + \epsilon \quad \text{or} \quad \theta^T \bar{x} + \epsilon$$

مثل همیشہ خطا کی نتیجه Error مانند تغییر دوستی باسیانی منفی است

البته پارامتر باسیانی میان میان را داخل  $\bar{x}$  منتظر کرده ایم (باشرط  $x_0 = 1$ )

$$\epsilon \sim N(0, \sigma^2)$$

$\xrightarrow{\text{باشرط میان میان}} \quad Y|x, \theta \sim N(\bar{x}\theta, \sigma^2)$

این از خاصیت جمع ثابت باندیل بسته است

$$P(y|x, \theta, \sigma^2) = \frac{1}{\sigma \sqrt{2\pi}} \exp \left[ \frac{-(y - \bar{x}^T \theta)^2}{2\sigma^2} \right]$$

حال پیشینی دست نهایی (Likelihood) مدل را بسته کردم.

$$L(\theta | D) = P(\theta) P(y|x, \theta) \stackrel{\text{iid.}}{=} \prod_{i=1}^N P(y_i|x_i, \theta) = \prod_{i=1}^N \frac{1}{\sigma \sqrt{2\pi}} \exp \left[ \frac{-(y_i - \bar{x}_i^T \theta)^2}{2\sigma^2} \right]$$

$$= \frac{1}{\sigma^n (2\pi)^{\frac{n}{2}}} \prod_{i=1}^N \exp \left[ \frac{-(y_i - \bar{x}_i^T \theta)^2}{2\sigma^2} \right] = \frac{1}{\sigma^n (2\pi)^{\frac{n}{2}}} \exp \left[ \sum_{i=1}^N \frac{-(y_i - \bar{x}_i^T \theta)^2}{2\sigma^2} \right]$$

$$\frac{1}{\sigma^n (2\pi)^{\frac{n}{2}}} \exp \left[ \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \bar{x}_i^T \theta)^2 \right]$$

حال دست داریم آن  $\theta$  ای را بسته کوچیم که  
اچال دین دیست را مانند سیمی کنیم.

$$\hat{\theta} = \arg \max L(\theta | D) \iff \hat{\theta} = \arg \max \log_e L(\theta | D)$$

مثال میگیریم که  $\log_e$  کردن خارساده شوند

$$\log_e L(\theta | D) = -\log_e \sigma^n (2\pi)^{\frac{n}{2}} + \log \left( \exp \left( -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \bar{x}_i^\top \theta)^2 \right) \right) =$$

مقدار ۲

~~$$g(\sigma) = -n \log \sigma (2\pi)^{\frac{1}{2}} - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \bar{x}_i^\top \theta)^2 = \text{const}_1 - \text{const}_2 \sum_{i=1}^n (y_i - \bar{x}_i^\top \theta)^2$$~~

↑  
جُمل دسته سی خذف می شود می‌شود

$$P(\theta) =$$
~~$$\ln L(\theta | D) = \alpha_1 + \alpha_2 \left( -\sum_{i=1}^n (y_i - \bar{x}_i^\top \theta)^2 \right) \Rightarrow \frac{\partial P}{\partial \theta} = -2 \sum_{i=1}^n (y_i - \bar{x}_i^\top \theta) \bar{x}_i =$$~~

$$-2 \sum_{i=1}^n y_i \bar{x}_i + 2 \sum_{i=1}^n (\bar{x}_i^\top \theta) \bar{x}_i = -2 \bar{x}^\top Y + 2 \bar{x}^\top X \theta = 0 \Rightarrow$$

$\bar{x}^\top X \theta = \bar{x}^\top Y \Rightarrow \hat{\theta} = \boxed{(\bar{x}^\top X)^{-1} \bar{x}^\top Y}$

معامل ضرب داخلی  
 $\bar{x}^\top Y$  or  $Y^\top \bar{x}$

بالآخره بسته اومد. حلایق دو تا ایده حساب نمی و سواله مت است او سن عالمی شود (عن سعادی الله)

٤

$$x_{new} = x_N = x_n$$

فرض کیم  $\hat{\theta}$  جبری جسے میں سینے پا سے  $x_{new}$  پر حاصل کر دیں  
(آن کا بدلی این است  $\theta$  کا عامل شوندگی)

~~$$\text{bias}_{new} = \text{bias} = (f(x) - \bar{g}(x))_{new}^2$$~~

$$f(x_{new}) = x_{new}^T \theta \rightarrow \text{ایج } \theta \text{ اصلی است}^{(\text{true})}$$

$$\begin{aligned} \bar{g}(x_n) &= E_{\mathcal{D}}[g(x_n)] = E[x_n^T \theta_{MLE}] = E[x_n^T (\bar{x}^T \bar{x})^{-1} \bar{x}^T Y] = E[x_n^T (\bar{x}^T \bar{x})^{-1} \bar{x}^T (\bar{x}\theta + \varepsilon)] \\ &= E[\underbrace{x_n^T (\bar{x}^T \bar{x})^{-1} \bar{x}^T \bar{x}}_{\theta} + x_n^T (\bar{x}^T \bar{x})^{-1} \bar{x}^T \varepsilon] = E[x_n^T \theta] + E[\underbrace{x_n^T (\bar{x}^T \bar{x})^{-1} \bar{x}^T \varepsilon}_{\varepsilon}] = x_n^T \theta \end{aligned}$$

$$\text{Bias} = (f(x) - \bar{g}(x))^2 = x_n^T \theta - x_n^T \theta = 0$$

$$\begin{aligned}
 \text{var} &= E_D[g^{(n)}(x) - \bar{g}(x)]^2 = E_D[(x_n^\top \theta_{\text{MLE}} - x_n^\top \theta)^2] = E_D[(x_n^\top (x^\top x)^{-1} x^\top y - x_n^\top \theta)^2] \\
 &= E_D[(x_n^\top (x^\top x)^{-1} x^\top (x\theta + \varepsilon) - x_n^\top \theta)^2] = E_D[(x_n^\top (x^\top x)^{-1} x^\top \theta + x_n^\top (x^\top x)^{-1} x^\top \varepsilon - x_n^\top \theta)^2] \\
 &= E_D[(x_n^\top \theta + x_n^\top (x^\top x)^{-1} x^\top \varepsilon - x_n^\top \theta)^2] = E_D[(x_n^\top (x^\top x)^{-1} x^\top \varepsilon)^2] = \\
 &= E_D[x_n^\top (x^\top x)^{-1} x^\top \varepsilon (x_n^\top (x^\top x)^{-1} x^\top \varepsilon)] = E[x_n^\top (x^\top x)^{-1} x^\top \varepsilon \varepsilon^\top x (x^\top x)^{-1} x_n] \\
 &= x_n^\top (x^\top x)^{-1} x^\top E[\varepsilon \varepsilon^\top] x (x^\top x)^{-1} x_n = x_n^\top (x^\top x)^{-1} x^\top \sigma_\varepsilon^2 x (x^\top x)^{-1} x_n = \\
 &\boxed{\sigma_\varepsilon^2 x_n^\top (x^\top x)^{-1} x_n} = \text{مدى مترافق مربع!}
 \end{aligned}$$

أول مسح

حست اسکل بعنی بین

این افراد کی لئے کسی روی  $w$  دایم و  $\beta$  را متعارف نقل کریں گے.

$$\beta = \frac{1}{\sigma^2}$$

$$P(w) = N(w | m_0, S_0)$$

بین مختصات  $w$  بودار  $m_0$  بودار بین مختصات داشتیں ہیں؟  
مختصات کو داریاں اسیں.

posterior  $\propto$  likelihood  $\times$  prior

$$y = f(x, w) + \epsilon \rightarrow N(0, \sigma^2) \text{ or } N(0, B^{-1})$$

یہ دایم بالمحاذی prior کو سی posterior کو سی خواهد بود زیرا

ابیات زیر ایسا La Conjugate prior

: posterior بنت آئیں.

$$\text{Likelihood} = P(y | X, w, \beta) = \prod_{n=1}^N N(y_n | w^T \varphi(x_n), B^{-1})$$

چون حرب صد prior حست دیکھی منزیب دار ما معناری کو ان تجزی لئے کامیابیں درودیں

Ex posterior

$$\begin{aligned}
 & \exp = \frac{-\beta}{2} \sum_{n=1}^N (y_n - w^T \psi(x_n))^2 + \frac{1}{2} (w - m_0)^T S_0^{-1} (w - m_0) \\
 & = \frac{-\beta}{2} \sum_{n=1}^N (y_n^2 - 2w^T \psi(x_n) y_n + w^T \psi(x_n) \psi(x_n)^T w) - \frac{1}{2} (w - m_0)^T S_0^{-1} (w - m_0) \\
 & = \frac{-1}{2} w^T \left[ \sum_{n=1}^N \beta \psi(x_n) \psi(x_n)^T + S_0^{-1} \right] w + \frac{1}{2} \left[ -2m_0^T S_0^{-1} - \sum_{n=1}^N 2y_n \psi(x_n)^T \right] w + \text{const} \\
 & \boxed{S_N^{-1} = S_0^{-1} + \cancel{\beta \psi(x_n) \psi(x_n)^T} + \cancel{\beta \psi^T \psi}} \quad (\text{جیسا استنارد دارم}) \\
 & \boxed{-2m_N^T S_N^{-1} = -2m_0^T S_0^{-1} - 2\beta \psi^T \psi \xrightarrow{x \frac{1}{2}}, \text{Transpose}} \quad (\text{جیسا عبارت دارم}) \\
 & \boxed{m_N = S_N^T (S_0^T)^{-1} m_0 + S_N^T \beta \psi^T \psi = S_N (S_0^{-1} m_0 + \beta \psi^T \psi)} \quad (\text{جیسا ساده مترن فرض نمی کنم})
 \end{aligned}$$

$$p(w|\alpha) = N(w|0, \alpha^{-1}I)$$

posterior  $\rightarrow m_N = B S_N \psi^T y$   
 $S_N = \alpha I + B \psi^T \psi$

$$p(y^* | x, y^*, \alpha, B) = \int_{\mathbb{R}^d} p(y^* | w, B) p(w | x, y^*, \alpha, B) dw$$

این خروجی جدید ما است مردادهای این دسکریپتیو خاصیت دارد که  $x^*$ ,  $y^*$  و داده های قبلی را در خواهیم داشت  
 $(x^*, y^*)$  new value

$$p(y^* | w, \beta) = N(y^* | f(x, w), \beta^{-1})$$

حال حی داشتم توزیع اولی بین مکمل است

و توزیع جدید را نتیجهست آوردم <sup>posterior</sup>

$$p(w | x^*, x, y, \alpha, \beta) = N(w | m_N, S_N)$$

$$\text{where } m_N = S_N^{-1} (S_0^{-1} m_0 + \beta \varphi^T y)$$

$$S_N^{-1} = S_0^{-1} + \beta \varphi \varphi^T$$

$$\begin{aligned} p(x) &= N(x | \mu, \Lambda^{-1}) \quad \text{دروی} \\ \text{و } p(y|x) &= N(y | Ax + b, L^{-1}) \end{aligned}$$

$$f(x, w) = w^T \varphi(x) \Rightarrow Ax + b \Rightarrow \begin{matrix} b = 0 \\ A = \varphi(x) \end{matrix} \quad \text{طابیت دادن فرمول}$$

$$L^{-1} = B^{-1} \Rightarrow L = B$$

$$\mu = m_N, \Lambda^{-1} = S_N^{-1}$$

$$\begin{aligned} \Rightarrow p(y^* | \cdot) &= N(y^* | m_N \varphi^T(x), \beta^{-1} + \varphi^T(x) S_N \varphi(x)) \\ &= N(y^* | m_N \varphi^T(x), \frac{1}{\beta} + \varphi^T(x) S_N \varphi(x)) \end{aligned}$$

لطفاً لایه لایه

$$\text{var}_1 = \sigma_e^2 x_n^T (\varphi(x))^T x_n$$

دایانس عددی بازبینی

$$\text{var}_2 = \frac{1}{\beta} + x^T S_N x = \sigma_e^2 + x^T S_N x$$

که شخصی شود بایس ها ضریب ندارند فقط دایانس روشن MLE صنعت است. برترین مقدار جوں پنهانہ ترین سل را از ابتداء فرضی کرد و اینجا یعنی که با قدر ای داده ها بعد از رسمی این دایانس میداند.

اگر بجای اینکه مقصود را در مدل ما از آبتدایی مقدار ثابت فرض نمی‌کنیم  
که ممکن است تعداد داده متوالی میل مسیر پارامترها باشند. لذا طبق

تعداد پارامترهای مدل بینت با افتراش تعداد داده لغزش پس از آنکه نه تنها overfitting  
کم می‌شود ~~آنچه~~

اما اگر تعداد داده‌ها به اندازه کافی باشد هر دو مدل خوب صفت و مقصود را دارند  
باشند.

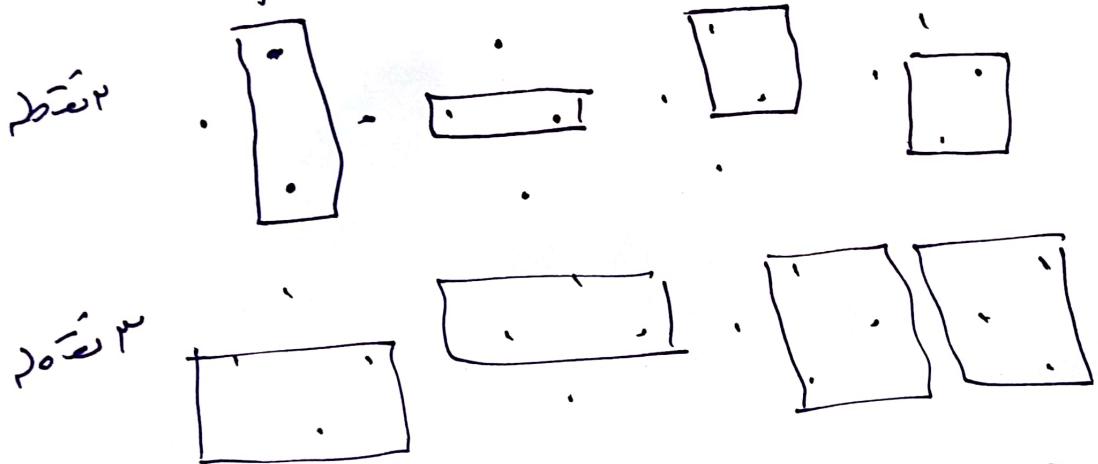
آنچه

سؤال ۲ ~~شکل~~ ۱ بعد VC ۴ است. چرا؟

۱- شکل ۳ نتیجه با configuration خاص وجود دارد که در آن شکل شووند shatter شوند.  
۲- صحیح نتیجه ای را در صحیح حالت فیتوان shatter برک.

برای اولین بخش واضح است که برای اول نتیجه توان shattering را به صورتی انجام داد.

برای ۲ نتیجه و ۳ نتیجه داریم.

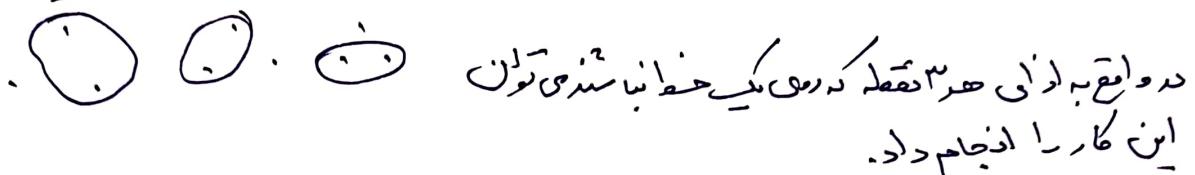


برای بخش دوم نتیجه داریم. ~~که~~ خالص خاص لغزش انتگرال بلی بدانند نتیجه را برداریم و می‌دانیم از آن های را انتگرال کنیم این درست است که سطحی مابا ۴ نتیجه به ازای هر لبه معینه سه واسع پس نتیجه ۵ ام یاری به است و یا داخل مستطیل است که این مارا از انتگرال باز میدارد.

۲) ساده ابعاد  $\Rightarrow$  ایه صادر مصال  $2\pi r^2$  است زیرا

- ۱) ۳ نقطه وجود دارد که آن کن صادر shatter نکر.
- ۲) چیزی ۳ نقطه لی را فی توان shatter نکر.

محبت اول: انتخاب چه از ۳ نقطه دیگری است. انتخاب ۲ نقطه دارم:



محبت دوم: ۱) اگر روی یک خط باشند که مطلاً این کار امکان پذیر نیست سلا ~~شتر~~ آخر  $-+-+$  ۲) قابل shatter نکن نیست.

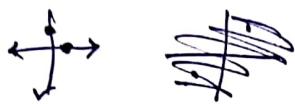
۱) اگر سلسله باشند نی تو ان کاری نکر نه ۳ نقطه بسیار باشند و نقطه دومنی متغیر باشد: (چهارمندلی صد)

۲) اگر در حالتی هم باشند چهارمندلی باشد. اگر از این خط عبارت باشد نمایش صیغه اولی و جو نظر در بتوان ۳ نقطه روی یک صدر ایجاد آن انتخاب نماید و دیگر انتخاب نماید. و اگر از این عبارت باشد صیغه ماه نی ترا دو نقطه روی صدر بزرگ شود آن انتخاب نکر.

کس در حالتی همیشی برای انتخاب ۳ نقطه وجود ندارد و مسدود شود شتر باید.

breakpoint = 4

(۳) تعداد ابعاد  $VC$  برای مساحتی در از پیدائی لذت دهنده دفعات  $R^D$  صاف  $\mathcal{P}_{ad}$  است.



سلا ۲ نعمت دفعات  $2$  بینی تو ان بر افق shatter نکر.

اینها مجموعه دعا کار نیستند از قابل بزرگی و دوایه های  $x_i$  به این تصورات نمی پوشند:

$$x_{ij} = (i=j)$$

$x_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, x_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \dots, x_n = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$  به سادگی هی تو ان باشی دسته به حمل کام لیل خواهد شد: تو لیل نیز:

$$j = \{-n+1\}$$

$$f = \text{sgn}(\bar{w}^T x) = \text{sgn}\left(\sum_{i=1}^n w_i x_i\right) \rightarrow f(x_j) = \text{sgn}\left(\sum_{i=1}^n w_i x_{ij}\right) = \text{sgn}(w_j)$$

پس هی تو ان حد را از عبارت  $f(x_j) = \text{sgn}(\sum_{i=1}^n w_i x_{ij})$  پاسخ می دهد و دسته بندی شود رابین مردم فرمول نمی

$$\boxed{VC \geq d}$$

ما شatter شود. پس داریم

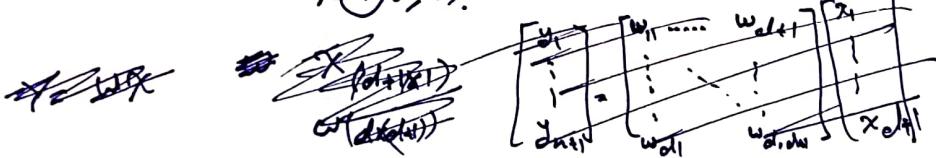
حال بایه بگوییم  $VC < d+1$ . باز فرض نمی کنیم اینه نعمت دارم دفعات لذت دهنده مساحتی هم بعیتی

$$S = \{x_1, \dots, x_{d+1}\}$$

$$f_i(x) = \text{sgn}(w_k^T x)$$

کل بایه بتوانیم همه حالت های احتمالی شنی پس بایه

میں یک دسته ای متعال حییی داریم و خدا این دسته دیدار کار.



حال می دایم بجهت این دفعات داده داریم و  $d+1$  مجموع داشته باشند

$$VC < d+1$$

$$Y = \begin{bmatrix} y_1 \\ \vdots \\ y_{d+1} \end{bmatrix} = \begin{bmatrix} w_1, \dots, w_{d+1} \\ \vdots \\ w_{d+1}, w_{d+1} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_{d+1} \end{bmatrix}$$

$$\boxed{VC = d}$$

$$P(|E_{in}(g) - E_{out}(g)| > \varepsilon) \leq 2M \exp\{-2\varepsilon^2 N\}$$

$$\begin{aligned} \varepsilon &= 1.0 \\ \delta &= 0.1 \end{aligned}$$

١ ٢

$$\leq 4 M_H(2N) \exp\{-\frac{1}{8}\varepsilon^2 N\}^{s \leq s} = *$$

$$H_C \rightarrow \begin{cases} VC=3 \\ k=4 \end{cases} \quad m_H(2N) \leq \sum_{i=0}^{4-1} \binom{2N}{i} = 1 + 2N + \frac{2N(2N-1)}{2 \times 1} + \frac{2N(2N-1)(2N-2)}{3 \times 2 \times 1}$$

$$= \frac{4N^3}{3} + \frac{5N}{3} + 1$$

$$\text{حالات} * \Rightarrow \left(\frac{16N^3}{3} + \frac{20N}{3} + 4\right) \exp\{-0.0003725N\} \leq 0.1$$

$$N \geq 125424$$

جواب با استفاده از  
Simulator کامپیوتری  
بست آنکه بیوست ارسالی

متغیر از ملت ب این است که در ۹۰ درصد موافق دست ماحصل اهل ۹۵ درصد موافق بود.

از نیش بله تو صنع جسته

ملا عرض لئيم بسید رامیه در ۹۰ توب سیاه و ۱۰ توب مغزدار در ۹۵٪  
صیفیت خرچ توب سیاه از سید تو صیفیت تک در ۹۰ درصد موافق بود

توب سیاه یا صیفیت ۹۰ درصد خواهد بود.

### الف) پیوست Python Files

۱- پیوست ۲- مدل تایپ خارج و بالته به پارامتر ۶ نیز تایپ دارد

۳- بله تعداد دینگی ها بر عملکرد مدل تایپ خارج و بالته به پارامتر ۶ نیز تایپ دارد و درجه تعداد دینگی حبیت باشد محل پارامتر سیلیکاتی بینه جلوتری عدد (بینهای شور)

۲۳

۲۴

البته نتیجه بحث A و B یا همان کنایه های اندیکاتور دو سی دیجیتیکی پیوست شخص است اما دلکل کوسی عملکرد بهتری دارد ملصق همین است که صرفا به تفاهت یا شباهت دلکل او نمی دهد (وصی دلکل امساری می دهد) یعنی با توجه به فاصله دو بیان از نکدیدگیر شدید را تشخیص می کند که عطاً از روشن اندیکاتور مدائل سواره بهتر خواهد بود.

٣) بله تعداد دیگری ها بر صدر معنای پذیر دارد در واقعیت وان لفت که هرچه تعداد دیگری ها بجهت شرعاً احتمالاً پذیر است که بجهت بسته خواهد بود تابوتانه اش normalization خود را پذیرد.

البته تعداد دیگری های علیرغم مدلهم ناپذیر دارد و اگر تعداد دیگری های این زیاد است (مثل خواص مردمی های دیگر) ~~آن~~ ناپذیری های علیرغم مدل دارند

۳ ب د

آنچه خواصیم که تخمین کرد از نظر بدین مورد خواهد بود

$$\hat{r}(x) = \frac{\sum_{i=1}^n K\left(\frac{\|x_i - x\|^2}{h}\right) \cdot y_i}{\sum_{i=1}^n K\left(\frac{\|x_i - x\|^2}{h}\right)}$$

نیومن

که این بدهی

$$Bias(\hat{r}(x)) \leq A_1 h^2$$

$$var(\hat{r}(x)) \leq \frac{A_2}{nh}$$

باست آنکه که بعد از ضروریت است این است:

$\hat{r}(x)$  را در  
دسته ای از ابعاد

که این اندیشه ایجاد کل ابزار خواصیم داشت

$$Bias(\hat{r}(x)) \leq A_1 h^2$$

$$var(\hat{r}(x)) \leq \frac{A_2}{nh}$$

$$h = \frac{C_2}{2C_1 n^{1/3}}$$

و این  $A_1, A_2$  هم رابطه با  $n$  دارند

۴) به نظری اگر دش رکرسیون خلی تیجه بهتری خواهد داشت علت آن نیز به این مذکور  
برای کردن کنزل های گوسی بر بسیاری مشاهدات داره به صوره داده هاده زیرا در حدود این امر حالتی است  
که دستی سوال ها باشد و حقیقت مطابق عرضی شود (ستاد فرع ماسن) معمولاً تغییر زناری  
در مسائلی محض (یا همراه بیری Prediction) بوجودی اگر دش گوسی همه این معادله ها قدرتمندی خواهند  
داشت اما در اینجا مسأله همچنان مفهومی حل های خامی در محاسبات لحاظ شود.